

Monitoreo transaccional: ¿qué revela el orden de las operaciones?

Evaluación del valor de modelos secuenciales para detección de fraude
Comité de Riesgos del Banco del Altiplano | Deep Learning 2026 | Equipo del Proyecto 1

Resumen ejecutivo

El banco necesitaba saber si leer las operaciones en secuencia justificaba cambiar un sistema basado en promedios, conteos y señales agregadas. Comparamos tres alternativas: A, sin secuencia ordenada; B, una GRU que recibió el historial en orden; y C, que combinó ambas representaciones. B sí utilizó el orden: en VALIDATION, su Average Precision (AP) cayó de 0.7207 a 0.2843 cuando permutamos exactamente los mismos eventos. Sin embargo, esa señal no se convirtió en una ventaja frente a A. En TEST, A alcanzó AP 0.9191 y un costo estimado de Q83,820; B y C costaron Q194,400 y Q147,780. El candidato final, definido antes de abrir TEST, fue A con threshold 0.055489. Su ahorro frente al propio A es Q0. Recomendamos **CONSERVAR**: mantener A y no incorporar secuencias todavía, aunque el hallazgo sobre el orden merece validarse con datos reales.

1. La decisión y los datos

La pregunta no era si podíamos entrenar una red recurrente, sino si la secuencia añadía una señal útil, en qué fraudes y con qué impacto económico. El sistema actual se representa conceptualmente con A: operación actual más resúmenes causales del comportamiento de la tarjeta.

Origen	Transacciones	Tarjetas	Periodo	Fraude
Generador sintético propio	95,767	2,800	1 ene.-29 jun. 2025	1.6446%

El generador incluyó testing_cashout, channel_takeover y amount_anomaly, además de viajes, compras grandes, rachas y microcompras legítimas difíciles. Esta construcción permite controlar la señal, pero no equivale a comportamiento bancario real.

2. Protocolo: medir hacia adelante

Cada ejemplo representa una transacción objetivo y hasta 12 operaciones anteriores de la misma tarjeta. TRAIN contiene el pasado más antiguo; VALIDATION sirvió para elegir modelos y thresholds; TEST quedó reservado para una única evaluación final.

Split	Periodo	Ejemplos	Fraudes
TRAIN	2025-01-01 a 2025-05-07	64,236	1,110
VALIDATION	2025-05-07 a 2025-06-03	14,365	228
TEST	2025-06-03 a 2025-06-29	14,366	222

Controles de fuga de información

El historial usa solo eventos anteriores al target. Scalers, imputación y vocabularios se ajustaron únicamente con TRAIN. Los tres modelos comparten targets y fronteras. El modelo candidato y los thresholds se congelaron antes de revisar TEST.




Figura 1. Partición cronológica común a los tres modelos.

3. Qué conseguimos sin utilizar el orden

A usa la operación actual y 23 resúmenes históricos; B usa una GRU con las operaciones en orden. Utilizamos AUC-PR/AP porque el fraude representa solo 1.64% de las transacciones y esta métrica se concentra en la calidad de detección de la clase fraudulenta. En VALIDATION, A alcanzó 0.9100 y B 0.7207. A fue claramente más competitivo.

4. ¿El orden realmente agregó información?

Tomamos exactamente las mismas operaciones de cada historial de VALIDATION y cambiamos únicamente el orden. No reentrenamos ni modificamos targets, longitudes o la operación actual.

Condición	AP en VALIDATION	Cambio
B original	0.7207	-
B permutado (media)	0.2843	-0.4363
B: últimos 3 eventos	0.7108	-0.0099




Figura 2. A aporta la referencia sin secuencia; las falsificaciones corresponden a B en VALIDATION.

La caída media tras permutar fue fuerte y consistente: 0.4363 AP, con desviación 0.0202 entre diez semillas. Esto aporta evidencia de que B estaba utilizando el orden. No prueba que B sea mejor que A ni que el mismo efecto aparecerá en datos reales.

El recorte responde otra pregunta. Mantuvimos el orden, pero conservamos solo los tres eventos más recientes. AP pasó de 0.7207 a 0.7108. Para este checkpoint, el contexto entre el cuarto y el duodécimo evento aportó poco; orden y cantidad de historia no son lo mismo.

5. Apuesta C: combinar secuencia y agregados

La hipótesis escrita antes de entrenar fue que combinar la secuencia con los resúmenes históricos podía mejorar el resultado porque ambas representaciones describen aspectos distintos del comportamiento. El control fue B.

Comparación en VALIDATION	AP	Diferencia
B - control	0.7207	-
C - híbrido	0.8152	+0.0945
C con agregados neutralizados	0.4295	-0.3857

C superó a B y la ablación confirmó que la rama agregada sí aportaba. La hipótesis cumplió su parte predictiva, pero no el criterio operativo completo: C quedó debajo de A y tuvo mayor costo final. No premiamos la complejidad por sí misma.

Resultados finales en TEST

El modelo y cada threshold se definieron antes de revisar TEST. AP resume la calidad del ranking; precision indica qué proporción de los bloqueos era fraude; recall, qué proporción del fraude fue detectada; F1 resume el equilibrio entre ambas.

Modelo	AP	Precision	Recall	F1	FN	FP	Costo
A	0.9191	0.502	0.950	0.657	11	209	Q83,820
B	0.7150	0.302	0.878	0.450	27	450	Q194,400
C	0.8248	0.378	0.905	0.533	21	331	Q147,780




Figura 3. Curvas Precision-Recall en TEST, usadas solo como evidencia descriptiva final.

6. Umbral y valor económico

Para traducir el score en una decisión usamos la aproximación acordada: cada fraude no detectado cuesta Q4,200 y cada operación legítima bloqueada cuesta Q180.

$$\text{Costo} = \text{FN} \times \text{Q4,200} + \text{FP} \times \text{Q180}$$

Cada modelo recibió su propio threshold, elegido exclusivamente en VALIDATION. A quedó congelado en 0.05548898. En TEST dejó pasar 11 fraudes y bloqueó 209 operaciones legítimas.

Referencia	Costo TEST	Diferencia frente a A
Never Block	Q932,400	Q848,580
A - candidato	Q83,820	Q0
B - secuencial	Q194,400	+Q110,580
C - híbrido	Q147,780	+Q63,960




Figura 4. Costo con thresholds congelados en VALIDATION.

La comparación principal es contra A, porque representa lo que puede lograrse sin secuencia. El candidato final también es A: ahorro frente a A = Q0. TEST cubrió 26.88 días; normalizado a 30.44 días, su costo equivalente es Q94,927 al mes. Esta cifra pertenece a la escala sintética y no debe extrapolarse a 1.4 millones de tarjetas.

7. Errores, límites y recomendación

Mecanismo	Fraudes	Detectados	No detectados	Recall
testing_cashout	134	133	1	99.3%
channel_takeover	75	71	4	94.7%
amount_anomaly	13	7	6	53.8%




Figura 5. Recall del candidato A por mecanismo en TEST.

Qué se equivocó

Seis de los once fraudes no detectados fueron amount_anomaly; todos los casos representativos tenían 12 eventos de historia, por lo que no se explican por historial corto. Entre los falsos positivos hubo microcompras, viajes, rachas de compras y una compra legítima grande. No encontramos un patrón único para todas las falsas alarmas.

Recomendación: CONSERVAR

Mantendríamos A. El orden contiene señal y C confirmó complementariedad, pero ni B ni C mejoraron AP o costo frente al modelo agregado. Antes de invertir en una solución secuencial, pediríamos una réplica con datos bancarios reales y costos operativos validados.

Límites y condiciones para cambiar la decisión

1) Los datos y mecanismos son sintéticos. 2) Q4,200/Q180 son costos medios simplificados. 3) La escala mensual no representa el universo real del banco. 4) La ventana de 12 eventos limita el contexto. 5) Puede existir drift. Cambiaríamos la recomendación si B/C mostraran ahorro sostenido en datos reales, si A perdiera recall en mecanismos críticos, si los falsos positivos fueran inaceptables o si aparecieran patrones donde la secuencia ofreciera una ventaja operativa verificable.

8. Matriz de evidencias

Esta matriz conecta cada afirmación central con una evidencia reproducible del repositorio. Las falsificaciones pertenecen a VALIDATION; la tabla final y los costos pertenecen a TEST.

Evidencia	Figura o tabla donde aparece	Conclusión	Limitación
Integridad de datos	figures/eda_temporal_split.png; artefactos/final_results.json#splits	TRAIN precede VALIDATION y VALIDATION precede TEST; preprocessing fue fit solo con TRAIN.	La integridad se comprobó sobre datos sintéticos y reglas del generador.
Comparación común A vs B	proyecto1_apellidos.ipynb §7-8; artefactos/final_results.json#models	A superó a B en Validation AP: 0.910021 vs 0.720674.	La diferencia mezcla representaciones y arquitecturas; no aísla por sí sola el orden.
Valor del orden	figures/order_permutation_validation.png; experiments/falsification_results.csv	Permutar los mismos eventos redujo AP de B de 0.720674 a 0.284325 ± 0.020168.	Demuestra sensibilidad al orden en B, no superioridad operativa frente a A.
Apuesta del equipo	figures/model_abc_validation_comparison.png; artefactos/model_c/model_c_metadata.json	C mejoró B a 0.815180 AP y la ablación de agregados cayó a 0.429477.	C quedó debajo de A y tuvo mayor costo final.
Decisión económica	figures/economic_cost_vs_threshold_validation.png; figures/test_economic_cost_abc.png	A fue prefijado con threshold 0.055489 y tuvo el menor costo TEST: Q83,820.	Q4,200/Q180 son costos medios simplificados; la cifra mensual usa escala simulada.
Recomendación y límites	figures/test_recall_by_mechanism_candidate.png; artefactos/final_evaluation.json	CONSERVAR A; las secuencias contienen señal pero no añadieron valor económico frente a A.	A tuvo recall 53.85% en amount_anomaly y falta validación con datos bancarios reales.

Decisión para el Banco del Altiplano

Con la evidencia disponible, conservaríamos el enfoque agregado A. No descartamos el valor científico del orden: la permutación mostró que existe. Lo que no observamos fue valor económico incremental suficiente para justificar una arquitectura secuencial. La siguiente decisión debe basarse en una validación controlada con datos reales, no en mayor complejidad técnica.

Fuentes internas: artefactos/final_results.json, artefactos/final_evaluation.json, artefactos/final_decision_config.json, metadata A/B/C, falsification_metadata.json, evidence_matrix.csv y audit_report.md.